

HEART

Hospital Environment Adaptive Routing Technique



(Tecnica di instradamento adattivo in ambiente ospedaliero)

IUORIO IRENE 0512119520



Domanda Iniziale

L'utilizzo di costi stimati tramite Machine Learning migliora la pianificazione di A*, oppure in alcuni casi può peggiorarne il comportamento rispetto all'uso di costi statici?



Motivazioni e Scelta del dominio

L'utilizzo di algoritmi di ricerca come A* e UCS presuppone costi noti e stabili

In un contesto ideale queste assunzioni sarebbero soddisfatte e gli algoritmi funzionerebbero perfettamente

Tuttavia, il mondo reale è caratterizzato da dinamicità e incertezza!



Scenario: Trasporto di emergenza di un paziente dall'ingresso dell'ospedale verso il reparto specifico


Obiettivo: Pianificare un percorso minimizzando il tempo totale di percorrenza

Modellazione dell'ambiente

- Grafo non orientato $G = (V, E)$
- Nodi V : posizioni rilevanti
- Archi E : corridoi con tempo di percorrenza

Algoritmi di ricerca utilizzati

- UCS (Uniform Cost Search)
- A* (Euristica Euclidea)



Simulazione dei costi di percorrenza

Poichè non sono disponibili dataset pubblici che descrivano in maniera dettagliata i tempi di percorrenza all'interno di un ambiente ospedaliero indoor, i dati utilizzati nel progetto **vengono generati tramite una simulazione controllata**.

Nel simulatore, la velocità reale utilizzata è pari a **1.4 m/s**.




Fattori che incidono sul tempo:

- Lunghezza del corridoio
- Tipo del corridoio
- Affollamento
- Congestione
- Eventi imprevisti (5%)
- Rumore naturale

Costi statici

Per ciascun corridoio del grafo, il simulatore calcola **200 volte** il tempo di percorrenza in diverse condizioni di orario e affollamento. A partire da questi valori viene quindi calcolata **la media dei tempi di attraversamento**.

Questa media viene utilizzata come costo statico del corridoio in UCS e A*.



È possibile stimare costi più realistici?

Modelli di Machine Learning per la stima dei costi

Il modello di machine learning non prende decisioni sul percorso finale, ma fornisce ad A* una funzione di costo alternativa rispetto ai costi statici.



Regressione Lineare



Random Forest

Valutazione delle prestazioni dei modelli

MAE

Quanto, in media, il modello sbaglia in secondi

RMSE

Errore quadratico medio

R^2

Quanto bene il modello spiega i dati

MAPE

Errore medio in percentuale

Scenari sperimentali e ambiente di test

I test sono stati condotti su un grafo di 26 nodi e su due scenari distinti, pensati per simulare livelli diversi di dinamicità all'interno di un ambiente ospedaliero.


Scenario normale

- Eventi imprevisti 3%

Scenario estremo

- Eventi imprevisti 10%

Per ciascuno scenario sono stati eseguiti 50 test di pianificazione confrontando le 4 configurazioni.




Riepilogo risultati

Table 2: Statistiche aggiuntive sui risultati					
Configurazione	Std costo (s)	Costo min (s)	Costo max (s)	Errore stima medio (s)	Tempo medio (ms)
Scenario normale					
Statico	28.20	51.54	165.77	21.91	0.07
Statico + Euclidea	38.44	38.68	205.69	31.12	0.07
ML Lineare	37.13	38.50	188.13	15.43	4.58
ML Random Forest	32.77	38.13	194.09	13.67	1327.12
Scenario estremo					
Statico	28.96	51.74	186.94	22.35	0.07
Statico + Euclidea	41.86	36.84	213.45	32.77	0.07
ML Lineare	39.04	40.94	194.20	18.40	4.63
ML Random Forest	31.34	38.14	165.22	19.90	1269.73

Table 1: Riepilogo dei risultati medi sui due scenari					
Configurazione	Costo medio (s)	Gap ottimo (%)	Soluzioni ottime (%)	Nodi espansi	Tempo (ms)
Scenario normale					
Statico	79.47	6.8	44.0	25.0	0.07
Statico + Euclidea	85.81	10.4	22.0	18.0	0.07
ML Lineare	84.57	9.2	22.0	25.5	4.58
ML Random Forest	78.13	2.4	56.0	22.6	1327.12
Scenario estremo					
Statico	83.47	5.2	40.0	25.0	0.07
Statico + Euclidea	90.19	7.7	40.0	19.0	0.07
ML Lineare	86.63	4.1	42.0	25.6	4.63
ML Random Forest	82.18	0.8	52.0	21.6	1269.73

L'utilizzo di costi stimati tramite Machine Learning migliora la pianificazione di A^* , oppure in alcuni casi può peggiorarne il comportamento rispetto all'uso di costi statici?

DIPENDE!




Nel complesso, questi risultati suggeriscono che il machine learning non debba sostituire gli approcci classici, ma **affiancarli** quando serve.

Gli **approcci tradizionali** restano la scelta migliore quando l'ambiente è **prevedibile**, mentre il **ML** diventa uno strumento davvero utile quando la **complessità e l'incertezza** rendono necessario adattare dinamicamente i costi.

Un'ultima piccola osservazione

L'euristica euclidea, si conferma utile per rendere la ricerca più efficiente, riducendo il numero di nodi esplorati. Tuttavia, i risultati mostrano che, **in ambienti molto dinamici**, esplorare meno nodi non garantisce automaticamente un percorso migliore. In altre parole, una buona euristica dal punto di vista geometrico non è e sempre una buona euristica dal punto di vista temporale.



Grazie per l'attenzione!

